

به نام خدا



توسعه سیستم ترکیبی GraphRAG برای بازیابی
هوشمند اطلاعات و پاسخ‌گویی مبتنی بر دانش

محمد معجونی

دانشجوی مهندسی کامپیوتر، دانشگاه ارومیه

تیر ماه ۱۴۰۵

چکیده

سیستم‌های تولید تقویت‌شده با بازیابی (Retrieval-Augmented Generation (RAG به مدل‌های زبانی امکان می‌دهند با اتکا به منابع دانشی خارجی، به پرسش‌های مرتبط با اسناد خصوصی یا اطلاعات خارج از داده‌های آموزشی پاسخ دهند. با این حال، روش‌های متداول بازیابی متنی در پاسخ‌گویی به پرسش‌های مفهومی و شناسایی ارتباط میان اطلاعات پراکنده در مجموعه‌های بزرگ اسناد با محدودیت‌های جدی مواجه هستند. در این پروژه، یک سیستم تولید تقویت‌شده با بازیابی مبتنی بر گراف GraphRAG طراحی و پیاده‌سازی شده است. این سیستم با استخراج موجودیت‌ها و روابط هم‌وقوعی از متن اسناد، یک گراف دانش جامع تشکیل داده و گره‌های مرتبط را در قالب اجتماعات معنایی سازمان‌دهی می‌کند. سپس با تولید خلاصه‌های ساخت‌یافته از اطلاعات هر اجتماع، امکان بازیابی دانش را در هر دو سطح جزئی و کلی فراهم می‌سازد. ترکیب هوشمندانه قطعات متنی، ساختار ارتباطی گراف و خلاصه اجتماعات، زمینه‌ای منسجم و مستند برای تولید پاسخ فراهم می‌آورد. ارزیابی‌های صورت‌گرفته نشان می‌دهد که این رویکرد ترکیبی در مقایسه با روش‌های بازیابی متنی ساده، پاسخ‌هایی بسیار مرتبط‌تر، جامع‌تر و ساخت‌یافته‌تر ارائه می‌دهد.

۱ مقدمه

مدل‌های زبانی بزرگ در سال‌های اخیر توانایی بی‌نظیری در درک زبان طبیعی، تولید متن و پاسخ‌گویی به پرسش‌های پیچیده از خود نشان داده‌اند. با این حال، دانش درونی این مدل‌ها به داده‌های زمان آموزش محدود بوده و دسترسی مستقیمی به اسناد سازمانی، منابع اختصاصی یا پایگاه‌های داده به‌روز ندارند. افزون بر این، اتکای صرف به دانش درونی مدل

ممکن است به تولید پاسخ‌های نادرست، فاقد مستندات یا توهم‌زده منجر شود. از این رو، اتصال هوشمندانه این مدل‌ها به پایگاه‌های دانش خارجی به یکی از محورهای اصلی تحقیقات در پردازش زبان طبیعی تبدیل شده است.

معماری RAG برای حل این چالش، پیش از فرایند تولید پاسخ، قطعات متنی مرتبط را از اسناد هدف بازیابی کرده و آن‌ها را به عنوان زمینه در اختیار مدل قرار می‌دهد. در پیاده‌سازی‌های کلاسیک، اسناد به قطعات متنی کوچک‌تر تقسیم شده و قطعاتی که بیشترین شباهت برداری را با پرسش کاربر دارند انتخاب می‌شوند. اگرچه این روش برای پرسش‌های مستقیم و نقطه‌ای کارآمد است، اما قطعات متنی را به صورت کاملاً مستقل از یکدیگر ارزیابی می‌کند. در نتیجه، ساختار ارتباطی میان موجودیت‌ها، مفاهیم و رویدادهایی که در اسناد مختلف پراکنده شده‌اند، نادیده گرفته می‌شود.

این محدودیت زمانی بارزتر می‌شود که پاسخ یک پرسش مستلزم تلفیق اطلاعات از چند بخش مختلف یا تحلیل الگوی کلی داده‌ها باشد. پرسش‌هایی نظیر تحلیل موضوعات اصلی یک پایگاه داده، ارزیابی روابط میان گروه‌ها یا استخراج خلاصه‌های مدیریتی، تنها با بازیابی چند قطعه متنی مشابه به خوبی پاسخ داده نمی‌شوند. عدم وجود نگاه کل‌نگر و عدم مدلسازی صریح روابط در روش‌های سنتی، معمولاً به بازیابی ناقص و تولید پاسخ‌هایی با جامعیت محدود می‌انجامد.

رویکرد GraphRAG با هدف رفع این چالش، ساختار ارتباطی دانش موجود در اسناد را در قالب یک گراف مدل‌سازی می‌کند. در این رویکرد، موجودیت‌ها و روابط هم‌وقوعی از متن استخراج شده و به صورت گره‌ها و یال‌های گراف دانش بازنمایی می‌شوند. سپس شبکه حاصل با استفاده از الگوریتم‌های ساختاری به اجتماعات موضوعی تقسیم شده و برای هر اجتماع خلاصه‌ای جامع توسط مدل زبانی تولید می‌گردد. این زیرساخت امکان دسترسی به داده‌ها را هم در سطح جزئیات ساختیافته و هم در سطح مفاهیم کلی فراهم می‌سازد.

در این پروژه، یک سیستم جامع GraphRAG برای پردازش اسناد، ساخت گراف دانش هم‌وقوعی، الگوریتم‌ورزی اجتماعات و پاسخ‌گویی به پرسش‌ها طراحی و پیاده‌سازی شده است. در ادامه این گزارش، ابتدا مفاهیم پایه تشریح شده، سپس معماری کلی، مراحل پردازش، ساخت گراف، خلاصه‌سازی اجتماعات، مکانیزم‌های بازیابی، ارزیابی سیستم و در نهایت نتیجه‌گیری نهایی مورد بررسی قرار می‌گیرد.

۲ مفاهیم پایه و زیرساخت‌های نظری

در این بخش، مفاهیم و زیرساخت‌های نظری مورد نیاز برای تبیین معماری سیستم بررسی می‌شوند. این مفاهیم پایه‌ای نشان می‌دهند که چگونه سیستم از یک جست‌وجوی ساده مبتنی بر کلمات، به یک شبکه استنتاجی پیچیده گذار می‌کند.

۱-۲ تلفیق بازیابی معنایی و گراف دانش

در سیستم‌های سنتی RAG، اسناد به قطعات متنی تقسیم شده و تعبیه‌سازی (Embedding) می‌شوند تا پرسش کاربر بتواند نزدیک‌ترین قطعات را بر اساس شباهت کسینوسی در فضای چندبعدی بیابد. اگرچه این بازیابی برداری در یافتن قطعات متنی نزدیک عملکرد درخشانی دارد، اما توانایی استخراج مستقیم روابط شبکه‌ای میان موجودیت‌ها را ندارد. برای جبران این کاستی، از گراف دانش استفاده می‌شود. گراف دانش در این معماری، ساختاری پیوسته برای نمایش موجودیت‌ها به عنوان گره و ارتباطات متنی آن‌ها به عنوان یال است. با پیوند دادن بردارهای معنایی به گره‌های گراف، سیستم قادر است موجودیت‌های هم‌رخداد را رهگیری کرده و دانشی را که میان چندین پاراگراف یا سند توزیع شده است، به صورت یکپارچه بازیابی کند.


۲-۲ اجتماعات معنایی و پردازش سلسله‌مراتبی

گراف‌های دانش بزرگ می‌توانند شامل هزاران گره و یال باشند که پیمایش تمام آن‌ها در زمان پرس‌وجو غیرممکن و از نظر پردازشی پرهزینه است. به همین منظور، از مفهوم تشخیص اجتماعات استفاده می‌شود. یک اجتماع در گراف، خوشه‌ای از گره‌هاست که تراکم ارتباطی بالاتری با یکدیگر نسبت به سایر بخش‌های گراف دارند. این خوشه‌بندی به سیستم اجازه می‌دهد تا به جای پردازش خام و سطح‌پایین داده‌ها، گراف را به حوزه‌های موضوعی و رویدادهای مستقل تقسیم کند. با خلاصه‌سازی هر یک از این اجتماعات توسط مدل زبانی، سیستم به یک درک سلسله‌مراتبی دست می‌یابد؛ به این معنا که هم جزئیات متنی در پایین‌ترین سطح حفظ می‌شوند و هم مفاهیم کلان در قالب خلاصه‌های مدیریتی برای پرسش‌های کلی در دسترس خواهند بود.

۳ معماری کلی سیستم

معماری پیاده‌سازی‌شده در این پروژه، برپایه تفکیک کاملاً مستقل فاز پردازش سنگین اسناد از فاز برخط پاسخ‌گویی به پرسش استوار است. این ساختار باعث می‌شود عملیات زمانی و محاسباتی شدید مانند استخراج موجودیت‌ها، نگاشت شبکه‌ای و خلاصه‌سازی اجتماعات تنها یک‌بار انجام پذیرفته و در زمان دریافت پرسش کاربر، پاسخ‌ها با کمترین تأخیر و بالاترین دقت تولید شوند.

جریان داده در سیستم با دریافت اسناد خام آغاز می‌شود. متن‌ها پس از پاک‌سازی اولیه، به بلوک‌های معنایی قطعه‌بندی شده و هم‌زمان زیرساخت‌های برداری آن‌ها با استفاده از پایگاه داده ChromaDB شکل می‌گیرد. به موازات این مرحله، متون وارد خط لوله استخراج موجودیت می‌شوند تا گره‌ها و یال‌های گراف دانش ساخته شوند. پس از تکمیل گراف و وزن‌دهی یال‌ها، اجتماعات ساختاری با استفاده از الگوریتم‌های شبکه‌ای شناسایی شده و خلاصه‌های موضوعی آن‌ها توسط مدل زبانی تولید می‌گردند.



شکل ۱: جریان کلی پردازش و پاسخ‌گویی در سیستم


هنگام طرح پرسش از سوی کاربر، سیستم بر اساس نوع درخواست، مکانیزم بازیابی محلی، سراسری یا ترکیبی را فعال می‌سازد. در این مرحله، شباهت‌های کسینوسی متون در کنار امتیازات گرافی همسایگان ترکیب شده و پس از حذف تکرارها و رتبه‌بندی مجدد، زمینه‌ای غنی و همه‌جانبه آماده می‌گردد. این کانتکست ساختاریافته در نهایت در اختیار یک نشست

اختصاصی قرار می‌گیرد که با اتکا به تاریخچه مکالمه، اقدام به تولید پاسخ نهایی مستند می‌کند. تمامی این مراحل در محیط‌هایی کاملاً ایزوله برای هر نشست کاربر مدیریت می‌شوند تا از تداخل اطلاعاتی جلوگیری گردد.

۴ پردازش و آماده‌سازی اسناد

کیفیت ورودی خط لوله پردازش اسناد، تعیین‌کننده دقت مراحل بعدی در استخراج دانش است. هدف این مرحله، تبدیل اسناد غیرساختاریافته به قطعات متنی استاندارد، باکیفیت و دارای فراداده‌های کامل است که امکان رهگیری دقیق اطلاعات را در زمان پاسخ‌گویی فراهم سازد.

TEXT PREPROCESSING AND SEMANTIC CHUNKING FOR RAG SYSTEM



شکل ۲: مراحل پیش‌پردازش، قطعه‌بندی متن و تولید بردارهای معنایی

۴-۱ استخراج، پیش‌پردازش و قطعه‌بندی


در نخستین گام، محتوای متنی از فایل‌های ورودی استخراج شده و فراداده‌های کلیدی نظیر نام سند و موقعیت متنی ثبت می‌گردند. متن استخراج‌شده تحت فرآیند پاک‌سازی قرار می‌گیرد تا نویسه‌های کنترلی، خطوط خالی متوالی، تگ‌های HTML و ارجاعات عددی غیرضروری حذف شوند. در این مرحله از پاک‌سازی‌های افراطی پرهیز می‌شود تا ساختار نحوی جملات

برای عملکرد درست ابزارهای استخراج موجودیت آسیب نبیند.

به دلیل محدودیت پنجره کانتکست در مدل‌های زبانی، اسناد طولانی بر اساس تعداد توکن‌ها به قطعات متنی تقسیم می‌شوند. در پیاده‌سازی این سیستم، اندازه استاندارد هر قطعه ۵۰۰ توکن و میزان هم‌پوشانی میان قطعات مجاور حدود ۸۰ توکن تنظیم شده است. این هم‌پوشانی تضمین می‌کند که مفاهیم موجود در مرز پاراگراف‌ها شکسته نشده و پیوستگی معنایی حفظ شود.

۲-۴ بردارسازی و نمایه‌سازی پویا

متن هر قطعه پس از برش، توسط مدل تعبیه‌سازی به یک بردار متراکم تبدیل شده و به صورت دسته‌ای در پایگاه داده برداری ذخیره می‌گردد. سیستم برای هر قطعه متنی، ساختار داده‌ای جامعی شامل شناسه یکتا، متن، نام سند منبع، شماره قطعه و شناسه نشست کاربر تشکیل می‌دهد. از آنجا که این سیستم پویاست، با بارگذاری هر سند جدید، قطعات قبلی همان منبع بازنویسی شده و الگوریتم‌های تشخیص اجتماع و خلاصه‌سازی مجدداً اجرا می‌شوند تا دانش سطح کلان سیستم همواره با آخرین وضعیت اسناد مطابقت داشته باشد.



شکل ۳: روند استخراج موجودیت‌ها، پاک‌سازی و تشکیل گراف هم‌وقوعی وزن‌دار

۵ ساخت گراف دانش هم‌وقوعی

پس از آماده‌سازی قطعات متنی، فاز استخراج شبکه ارتباطی مفاهیم آغاز می‌گردد. در این رویکرد، به جای استخراج روابط صریح (که بسیار زمان‌بر و خطاپذیر است)، یک گراف هم‌وقوعی موجودیت‌ها تشکیل می‌شود که در آن ارتباط موجودیت‌ها بر اساس حضور هم‌زمان آن‌ها در یک بستر معنایی مشترک تعریف می‌گردد.

۵-۱ استخراج و یکپارچه‌سازی موجودیت‌ها

متن هر قطعه توسط خط لوله پردازش زبان طبیعی بررسی شده و موجودیت‌های نام‌دار در دسته‌های اصلی شامل اشخاص، سازمان‌ها، موقعیت‌های جغرافیایی، رویدادها، قوانین و موارد مشابه استخراج می‌شوند. محدود کردن استخراج به این رده‌های مشخص، از شلوغ شدن گراف با کلمات عام جلوگیری می‌کند. برای جلوگیری از دوتایی شدن گره‌ها، اسامی نرمال‌سازی شده و موارد نامعتبر (مانند رشته‌های تماماً عددی یا بسیار کوتاه) حذف می‌شوند. یکی از مهم‌ترین چالش‌های ساخت گراف، یکپارچه‌سازی اسامی مشابه است. برای این منظور، از یک ماژول پاک‌سازی مبتنی بر مدل زبانی استفاده می‌شود که موجودیت‌های استخراج شده را دریافت کرده و با تحلیل نام و نوع آن‌ها، نام‌های مترادف یا املای متفاوت از یک موجودیت واحد را در یک گره متعارف ادغام می‌کند. این فرایند برای جلوگیری از فشار بر محدودیت توکن مدل زبانی، به صورت دسته‌ای و موازی انجام می‌پذیرد.


۵-۲ ایجاد یال‌ها و سازمان‌دهی شبکه‌ای

به ازای هر موجودیت یکتا، یک گره ایجاد شده و شاخص تکرار آن بر اساس حضور در قطعات مختلف افزایش می‌یابد. برای تمامی موجودیت‌های معتبری که در یک دامنه متنی مشترک (مانند یک جمله) حضور دارند، زوج‌های دو به دو تشکیل شده و یال‌های بدون جهت میان آن‌ها ترسیم می‌شوند. وزن هر یال در این شبکه معادل تعداد قطعاتی است که آن دو موجودیت در آن‌ها به طور مشترک ظاهر شده‌اند.

وزن بالاتر یال، نشان‌دهنده پیوند متنی قوی‌تر میان دو موجودیت است. این وزن‌ها سیگنال ساختاری قدرتمندی برای رتبه‌بندی همسایگی و کشف اجتماعات فراهم می‌آورند. در نهایت، گراف شکل‌گرفته به همراه نگاشت جامع گره‌ها به شناسه‌های قطعات متنی در قالب یک فایل در دیسک ذخیره می‌شود تا در زمان پاسخ‌گویی به سرعت در دسترس باشد.

۶ تشخیص اجتماعات و خلاصه‌سازی کلان

در شبکه‌های پیچیده و متراکم، استخراج بینش‌های کلان نیازمند تحلیل ساختاری است. به همین دلیل، گره‌های گراف بر اساس تراکم یال‌هایشان به اجتماعات موضوعی گروه‌بندی شده و اطلاعات هر اجتماع طی فرآیندی هوشمند، مستندسازی و خلاصه می‌شود.



شکل ۴: فرایند تشخیص اجتماعات ساختاری و تولید خلاصه‌های کلان مدیریتی

۱-۶ تحلیل ماژولاریتی و انتخاب موجودیت‌های مرکزی

ابتدا گراف به مؤلفه‌های همبند مجزا تقسیم می‌شود. سپس بر روی هر مؤلفه، الگوریتم پیشینه‌سازی حریصانه ماژولاریتی اعمال می‌گردد. این الگوریتم با در نظر گرفتن وزن یال‌ها، گراف را به گونه‌ای برش می‌دهد که تراکم یال‌های درون‌گروهی در هر اجتماع نسبت به یال‌های برون‌گروهی به حداکثر برسد. پس از تفکیک، موجودیت‌های هر اجتماع بر اساس فراوانی متنی و درجه وزن‌دارشان در گراف، رتبه‌بندی می‌شوند تا گره‌های مرکزی و کلیدی مشخص گردند.

۲-۶ استخراج شواهد و تولید خلاصه‌های مدیریتی


از آنجا که ارسال تمام قطعات متنی مرتبط با یک اجتماع به مدل زبانی امکان‌پذیر نیست، سیستم با استفاده از یک الگوریتم انتخاب نماینده، قطعاتی را گلچین می‌کند که بیشترین

پوشش را روی موجودیت‌های کلیدی داشته و از تنوع بالایی برخوردار باشند. این شواهد متنی به همراه لیستی از موجودیت‌های مرکزی، به یک مدل زبانی ارسال می‌شوند تا خلاصه‌ای ساخت‌یافته شامل موضوع غالب و روابط کلیدی تولید شود.

این فرآیند به صورت موازی و با محدودیت تعداد پردازشگرها انجام می‌شود تا از سقف مجاز درخواست‌های شبکه تخطی نشود. در نهایت، خلاصه‌های تولیدشده به بردار معنایی تبدیل شده و در یک ماتریس قرار می‌گیرند تا بستر لازم برای پاسخ‌گویی به پرسش‌های سراسری و کلان فراهم آید.

۷ روش‌های بازیابی و رتبه‌بندی نتایج

قدرت اصلی این سیستم در ترکیب رویکردهای متنوع بازیابی در زمان پرس‌وجو نهفته است. سیستم با ادغام جست‌وجوی محلی (تمرکز بر جزئیات و همسایگان گرافی) و جست‌وجوی سراسری (تمرکز بر خلاصه‌های کلان)، اطلاعات را غربال کرده و متراکم‌ترین زمینه را برای تولید پاسخ فراهم می‌سازد.



شکل ۵: مراحل بازیابی چندوجهی، ادغام نتایج (RRF) و رتبه‌بندی مجدد

۱-۷ باز یابی چندوجهی و ادغام با RRF

فرایند باز یابی محلی با دو مکانیزم موازی آغاز می شود: جست و جوی متراکم برداری برای یافتن مفاهیم مشابه، و جست و جوی پراکنده واژه محور (BM25) برای استخراج اسامی خاص و اصطلاحات دقیق. نتایج این دو سیستم از طریق الگوریتم ادغام رتبه متقابل (Reciprocal Rank Fusion) با یکدیگر ترکیب می شوند تا تعادلی ایده آل میان درک معنا و دقت کلمه ای برقرار گردد.


پس از استخراج بهترین قطعات متنی، سیستم موجودیت های حاضر در آن ها را با گراف دانش تطبیق داده و همسایگان قدرتمند آن ها را استخراج می کند. با استخراج متون متصل به این همسایگان گرافی، دامنه اطلاعات توسعه یافته و مستندات باز یابی می شوند که ممکن است از نظر واژگانی با پرسش متفاوت باشند اما از لحاظ ساختاری با آن گره خورده اند.

۲-۷ باز یابی سراسری و رتبه بندی مجدد

برای پاسخگویی به ابعاد کلان پرسش، سیستم بردار معنایی سوال کاربر را با بردارهای خلاصه اجتماعات مقایسه می کند. سه اجتماع که بالاترین تطابق را داشته باشند انتخاب شده و خلاصه های آن ها به همراه قطعات پشتیبان شان به مجموعه نتایج افزوده می شوند. در حالت باز یابی ترکیبی، نتایج محلی و سراسری با یکدیگر ادغام می شوند (با اعمال ضریب جریمه بر روی امتیازات سراسری جهت حفظ اولویت مستندات دقیق محلی). سپس تمام قطعات نامزد پس از حذف تکرارها، در اختیار یک مدل رتبه بندی مجدد متقاطع (CrossEncoder) قرار می گیرند تا ارتباط معنایی دقیق هر قطعه با پرسش سنجیده شده و نویزهای ناشی از باز یابی اولیه حذف گردند. خروجی نهایی، بلوک های استاندارد از متون مستند است که برای تزریق به پرامپت نهایی فرمت دهی شده اند.

۸ تولید پاسخ و مدیریت نشست ها

فاز تولید، شامل تلفیق کانتکست ساخت یافته با تاریخچه مکالمات کاربر جهت تولید یک پاسخ روان، مستند و عاری از توهّمات مصنوعی است.



شکل ۶: مراحل تولید پاسخ مستند و مدیریت جریان مکالمه

۱-۸ مدیریت تاریخچه و بازنویسی پرسش

با هر درخواست، سیستم تا ۱۲ پیام اخیر رد و بدل شده میان کاربر و دستیار را بازیابی کرده و ترتیب زمانی آن‌ها را سازمان‌دهی می‌کند. چنانچه پرسش جدید کاربر دارای ضمائر ارجاعی به گذشته باشد، یک ماژول فرعی با استفاده از تاریخچه مکالمه، آن را به یک پرسش مستقل و کامل بازنویسی می‌کند تا دقت موتور بازیابی دچار افت نشود. با این حال، متن اصلی مکالمه دست‌نخورده باقی می‌ماند تا اصالت دیالوگ حفظ شود.

۲-۸ تولید پاسخ مستند و مدیریت خطا

پرامپت نهایی با ادغام دستورالعمل‌های سخت‌گیرانه سیستمی، تاریخچه مکالمه و زمینه بازیابی‌شده شکل می‌گیرد. مدل زبانی با دمای صفر فراخوانی می‌شود تا کمترین میزان تصادف و بالاترین سطح اتکا به متن را داشته باشد. به مدل تأکید می‌شود که منحصراً بر پایه شواهد ارائه‌شده پاسخ دهد و در صورت فقدان اطلاعات، صراحتاً اعلام کند که شواهد کافی در دسترس نیست. پس از تولید پاسخ، نشانگرهای ارجاعی پاک‌سازی شده و اسامی دقیق فایل‌های منبع در انتهای خروجی فهرست می‌شوند. در نهایت، پاسخ سیستم به همراه اطلاعات مفصل فراداده‌ها در حافظه نشست کاربر ذخیره می‌گردد.

۹ ارزیابی سیستم و تحلیل نتایج

برای بررسی کارایی سیستم طراحی شده، ارزیابی جامعی بر روی مجموعه داده استاندارد novel از پلتفرم Hugging Face صورت گرفته است. نتایج این ارزیابی با تفکیک دو فاز اصلی «بازیابی اطلاعات» و «تولید متن» تحلیل شده‌اند و نشان‌دهنده الگوهای رفتاری بسیار امیدوارکننده‌ای در معماری GraphRAG هستند.

۱-۹ معیارهای ارزیابی

پیش از پرداختن به تحلیل کمی و کیفی نتایج، تشریح دقیق معیارهای به‌کاررفته برای سنجش عملکرد سیستم ضروری است. این شاخص‌ها به دو دسته کلی مرتبط با فاز بازیابی و فاز تولید تقسیم می‌شوند:

- **ارتباط متون (Context Relevancy):** این شاخص ارزیابی می‌کند که قطعات متنی بازیابی‌شده از گراف و پایگاه داده تا چه حد دقیقاً به پرسش کاربر مرتبط بوده و فاقد اطلاعات زائد یا نویز هستند.
- **پوشش بازیابی (Context Recall):** نشان‌دهنده توانایی سیستم در یافتن و استخراج تمامی قطعات متنی ضروری و پنهان در پایگاه داده است که برای شکل‌دهی یک پاسخ جامع به پرسش کاربر ضرورت دارند.
- **صحت پاسخ (Answer Correctness):** این معیار، درستی واقعیت‌ها و میزان تطابق معنایی پاسخ تولیدشده توسط سیستم را در مقایسه با پاسخ مرجع می‌سنجد.
- **نمره شباهت متنی (ROUGE Score):** شاخصی آماری برای محاسبه میزان هم‌پوشانی کلمات و عبارات بین خروجی مدل و متن مرجع است که به‌ویژه در وظایف استخراج فکت و خلاصه‌سازی کاربرد فراوان دارد.
- **وفاداری (Faithfulness):** معیاری حیاتی که میزان اتکا و پایبندی مدل زبانی به متون بازیابی‌شده را ارزیابی می‌کند. نمره بالای این شاخص به معنای مصونیت مدل در برابر پدیده توهم و عدم تولید اطلاعات ساختگی است.
- **پوشش مفاهیم (Coverage Score):** میزان دربرگیری موجودیت‌ها، رویدادها و مفاهیم کلیدی خواسته‌شده را در تولید پاسخ نهایی ارزیابی می‌کند.

۲-۹ نقاط قوت و عملکرد سیستم

تحلیل نتایج به دست آمده، ویژگی‌های عملکردی سیستم را در چندین شاخص کلیدی به وضوح نشان می‌دهد:

دقت در استخراج فکت‌ها: در وظایف بازیابی فکت (Fact Retrieval)، نمره ROUGE روی عدد 75.5% و شاخص صحت پاسخ روی 76.7% قرار دارد. این شاخص‌ها نشان می‌دهند که ساختار اندازه قطعات متنی و استفاده از تکنیک‌های زنجیره تفکر (Chain of Thought)، مانع از سردرگمی مدل در میان اسامی و موجودیت‌های متراکم می‌شود.

پایداری و وفاداری به متن: نقطه قوت بارز سیستم در فاز تولید، شاخص وفاداری است. ثبت امتیاز 91.6% در وظایف استدلال پیچیده و 89.9% در خلاصه‌سازی مفهومی، نشان می‌دهد که سیستم در «محدوده بدون توهم» عمل می‌کند. مدل زبانی تنها بر پایه شواهد بازیابی شده از گراف و پایگاه داده برداری پاسخ می‌دهد و از تولید اطلاعات ساختگی پرهیز می‌کند.

عملکرد در تولید خلاقانه: در وظایف تولید خلاقانه (Creative Generation)، صحت پاسخ عدد 83.3% و امتیاز پوشش مفاهیم مقدار 78.3% را ثبت کرده است. تنظیمات مرحله رتبه‌بندی، استخری غنی از اطلاعات را در اختیار مدل قرار می‌دهد که نتیجه آن، پوشش متناسب موجودیت‌ها و مفاهیم در داستان‌سرایی است.

بازیابی خالص متون: در بخش بازیابی، ارتباط متون در استدلال پیچیده برابر با 91.3% و در خلاصه‌سازی تحلیلی برابر با 92.8% است که عملکرد معماری Hybrid Search و رتبه‌بند را در پالایش نتایج نشان می‌دهد.

۳-۹ محدودیت‌ها و چالش‌های فعلی

در کنار شاخص‌های بالای ارتباط متون و وفاداری مدل، چالش اصلی سیستم در بخش پوشش بازیابی (Context Recall) مشهود است. اگرچه در پرسش‌های استدلال پیچیده پوشش 88.2% حاصل شده است، اما این نرخ در وظایف خلاصه‌سازی و بازیابی فکت به ترتیب روی اعداد 73.3% و 73.8% قرار دارد. ریشه‌یابی این چالش‌ها نشان‌دهنده محدودیت‌های ساختاری زیر در وضعیت فعلی سیستم است:

تراکم اطلاعاتی اسناد و پدیده خطای دید مدل: در برخی موارد خاص، سیستم با متون تاریخی به شدت متراکم مواجه است که استخراج تک‌تک فکت‌های پراکنده را با محدودیت روبه‌رو می‌سازد. به دلیل هم‌پوشانی بالای اسامی و رویدادها در یک بخش واحد، مکانیزم بازیابی گاهی در تفکیک فکت‌های ایزوله دچار خطا می‌شود.

چالش ادغام و پاک‌سازی گره‌ها: یکی از محدودیت‌های اساسی فعلی، عدم وجود یک لایه استاندارد برای پاک‌سازی و یکپارچه‌سازی نام‌ها در لبه‌های گراف است. وجود گره‌های تکراری با نگارش‌های متفاوت یا ارجاعات ضمیر نامشخص برای یک موجودیت واحد، باعث شکستگی روابط در گراف و در نتیجه کاهش نرخ پوشش در زمان بازیابی فکت‌ها می‌شود.

محدودیت خلاصه‌سازی اجتماعات کوچک: الگوریتم خلاصه‌سازی اجتماعات گراف در برخورد با گره‌های کم‌تکرار و چانک‌های متنی ایزوله، مستعد حذف جزئیات ریز رابطه‌ای است که این امر مستقیماً جامعیت پاسخ را در تسک‌های خلاصه‌سازی تحت تأثیر قرار می‌دهد.

۴-۹ توسعه و کارهای آینده

با توجه به ارزیابی‌های انجام‌شده و چالش‌های مشاهده‌شده در عملکرد سیستم، مسیر توسعه و کارهای آینده باید بر رفع محدودیت‌های فعلی در پردازش متون پیچیده و بهینه‌سازی ساختار گراف متمرکز شود:

ارتقای مکانیزم رتبه‌بندی (Reranking): بررسی‌ها نشان می‌دهد که سیستم در برخورد با حجم بالایی از متون پیچیده و طولانی، عملکرد بهینه‌ای در رتبه‌بندی مجدد نتایج از خود نشان نمی‌دهد. از این رو، طراحی و پیاده‌سازی مکانیزم‌های کارآمدتر و هوشمندانه‌تر برای فیلتر و رتبه‌بندی دقیق این نوع متون ضروری است.

افزایش خلوص و انسجام خلاصه‌ها: خلاصه‌های تولیدشده در وضعیت فعلی از خلوص و تمرکز کافی برخوردار نیستند و در بسیاری از موارد، گره‌ها و موجودیت‌های مختلف به شکل نامنظمی در آن‌ها با یکدیگر در هم آمیخته‌اند. بهبود الگوریتم‌های خلاصه‌سازی برای تولید خروجی‌های دقیق‌تر و جلوگیری از تداخل اطلاعاتی گره‌ها در دستور کار قرار دارد.

یکتاسازی گره‌ها و بهبود ساختار اجتماعات: فرآیند ساخت گراف باید به‌گونه‌ای اصلاح شود که ثبت موجودیت‌ها بر پایه گره‌های کاملاً یکتا صورت پذیرد. همچنین، الگوریتم‌های تشخیص اجتماع باید بهینه‌سازی شوند تا اجتماعاتی باکیفیت، معنادار و بدون هم‌پوشانی یا تکرار زائد شکل بگیرند که این امر مستقیماً بر کیفیت پردازش‌های بعدی تأثیرگذار خواهد بود.

۱۰ کلام آخر

در این پروژه، معماری نوینی برای سیستم‌های پرسش و پاسخ مبتنی بر اسناد با ادغام گراف دانش توسعه یافت. این سیستم با گذر از محدودیت‌های رایج در بازیابی صرفاً متنی، شبکه‌ای

معنایی از موجودیت‌ها و روابط آن‌ها تشکیل می‌دهد. یافته‌ها نشان داد که بهره‌گیری هم‌زمان از جست‌وجوی متراکم برداری، گراف‌های هم‌وقوعی و خلاصه‌های کلان اجتماعات، کیفیت زمینه ارائه‌شده به مدل زبانی را به‌طور قابل‌توجهی ارتقا می‌بخشد. بر اساس ارزیابی‌های صورت‌گرفته، سیستم GraphRAG در حفظ وفاداری به مستندات و جلوگیری از توهم زبانی موفقیت چشمگیری داشته است؛ هرچند ارتقای نرخ پوشش در فاز بازیابی، کلید دستیابی به استدلال‌های جامع‌تر و دقیق‌تر در آینده خواهد بود. در نهایت، معماری ارائه‌شده بستری مقیاس‌پذیر، قابل‌اعتماد و ساخت‌یافته برای توسعه دستیارهای هوشمند و تحلیل‌گرهای پیشرفته متون فراهم می‌آورد.